Министерство науки и высшего образования Российской Федерации
Калужский филиал
федерального государственного автономного
образовательного учреждения высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(КФ МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ***ИУК «Информатика и управление»***

КАФЕДРА ***ИУК5 «Системы обработки информации»***

Практическая работа № 1

«Базовые навыки работы в Jupiter Notebook»

ДИСЦИПЛИНА: «Технологии обработки больших данных»

Выполнил: студент гр.ИУК5-82Б _____ (Ли Р.В. _____)
(Подпись) (Ф.И.О.)

Проверил: _____ (_____)
(Подпись) (Ф.И.О.)

Дата сдачи (защиты):

Результаты сдачи (защиты):
- Балльная оценка:
- Оценка:

Калуга, 2026

Цель лабораторной работы - освоить базовые навыки работы в Jupyter Notebook для дальнейшего выполнения лабораторных по анализу данных: создание и оформление ноутбука, выполнение кода, получение вывода, простая визуализация и загрузка данных.

Задачи:

- разобраться, что такое Anaconda и Jupyter Notebook, и какую роль играет ядро (kernel);
- научиться работать с ячейками: создавать, удалять, менять тип (Code/Markdown);
- выполнить примеры с Markdown-разметкой и запуском Python-кода;
- сделать простой пример визуализации (график/точечная диаграмма);
- загрузить небольшой датасет (например, load_iris), собрать его в pandas DataFrame и вывести первые строки;
- выполнить задание для самостоятельной работы, используя библиотеки: pandas (работа с таблицами), numpy (вычисления и фильтрация) и matplotlib/seaborn (визуализация).

Задание для самостоятельной работы

Выполните следующее задание в отдельном (новом) Jupyter Notebook, используя Python и библиотеки pandas (основная работа с таблицами), при необходимости numpy (вычисления и фильтрация) и matplotlib/seaborn (визуализация). Датасет загрузите с помощью pandas.read_csv.

В задании предлагается с помощью Pandas ответить на несколько вопросов по данным репозитория UCI Adult.

Уникальные значения признаков (больше информации по ссылке выше):

- age: continuous.
- workclass: Private, Self-emp-not-inc, Self-emp-inc, Federal-gov, Local-gov, State-gov, Without-pay, Never-worked.
- fnlwgt: continuous.
- education: Bachelors, Some-college, 11th, HS-grad, Prof-school, Assoc-acdm, Assoc-voc, 9th, 7th-8th, 12th, Masters, 1st-4th, 10th, Doctorate, 5th-6th, Preschool.
- education-num: continuous.
- marital-status: Married-civ-spouse, Divorced, Never-married, Separated, Widowed, Married-spouse-absent, Married-AF-spouse.
- occupation: Tech-support, Craft-repair, Other-service, Sales, Exec-managerial, Prof-specialty, Handlers-cleaners, Machine-op-inspct, Adm-clerical, Farming-fishing, Transport-moving, Priv-house-serv, Protective-serv, Armed-Forces.
- relationship: Wife, Own-child, Husband, Not-in-family, Other-relative, Unmarried.
- race: White, Asian-Pac-Islander, Amer-Indian-Eskimo, Other, Black.
- sex: Female, Male.
- capital-gain: continuous.
- capital-loss: continuous.
- hours-per-week: continuous.

- native-country: United-States, Cambodia, England, Puerto-Rico, Canada, Germany, Outlying-US(Guam-USVI-etc), India, Japan, Greece, South, China, Cuba, Iran, Honduras, Philippines, Italy, Poland, Jamaica, Vietnam, Mexico, Portugal, Ireland, France, Dominican-Republic, Laos, Ecuador, Taiwan, Haiti, Columbia, Hungary, Guatemala, Nicaragua, Scotland, Thailand, Yugoslavia, El-Salvador, Trinadad&Tobago, Peru, Hong, Holand-Netherlands.
- salary: >50K,<=50K

1. Сколько мужчин и женщин (признак sex) представлено в этом наборе данных?



```
[6]: df["sex"].value_counts()

[6]: sex
     Male      2549
     Female    2451
     Name: count, dtype: int64
```

2. Каков средний возраст (признак age) женщин?



```
[7]: df[df["sex"] == "Female"]["age"].mean()

[7]: np.float64(43.605059159526725)
```

3. Какова доля граждан Германии (признак native-country)?



```
[8]: (df["native-country"] == "Germany").mean()

[8]: np.float64(0.1412)
```

4-5. Каковы средние значения и среднеквадратичные отклонения возраста тех, кто получает более 50K в год (признак salary) и тех, кто получает менее 50K в год?



```
[9]: df.groupby("salary")["age"].agg(["mean","std"])
```

salary	mean	std
<=50K	43.843664	14.863572
>50K	43.318606	14.974235

6. Правда ли, что люди, которые получают больше 50k, имеют как минимум высшее образование? (признак education – Bachelors, Prof-school, Assoc-acdm, Assoc-voc, Masters или Doctorate)

```
[10]: higher_education = [
          "Bachelors","Prof-school","Assoc-acdm",
          "Assoc-voc","Masters","Doctorate"
      ]

      df[df["salary"] == ">50K"]["education"].isin(higher_education).all()
```

```
[10]: np.False_
```

7. Выведите статистику возраста для каждой расы (признак race) и каждого пола. Используйте groupby и describe. Найдите таким образом максимальный возраст мужчин расы Amer-Indian-Eskimo.

```
[11]: df.groupby(["race","sex"])["age"].describe()
```

[11]:

race	sex	count	mean	std	min	25%	50%	75%	max
Amer-Indian-Eskimo	Female	482.0	43.489627	14.693433	18.0	31.0	43.0	56.0	69.0
	Male	498.0	43.853414	14.791937	18.0	31.0	44.0	57.0	69.0
Asian-Pac-Islander	Female	514.0	43.509728	15.200188	18.0	30.0	43.0	56.0	69.0
	Male	525.0	44.177143	14.465445	18.0	33.0	44.0	56.0	69.0
Black	Female	466.0	43.736052	14.812414	18.0	31.0	44.0	56.0	69.0
	Male	496.0	43.322581	14.968545	18.0	31.0	42.5	56.0	69.0
Other	Female	512.0	43.453125	15.292892	18.0	30.0	45.0	57.0	69.0
	Male	507.0	43.078895	14.982127	18.0	30.0	43.0	56.0	69.0
White	Female	477.0	43.859539	15.028655	18.0	31.0	44.0	57.0	69.0
	Male	523.0	43.376673	15.029396	18.0	30.0	43.0	56.0	69.0

```
[12]: df[(df["race"]=="Amer-Indian-Eskimo") & (df["sex"]=="Male")]["age"].max()
```

```
[12]: np.int64(69)
```

8. Среди кого больше доля зарабатывающих много (>50K): среди женатых или холостых мужчин (признак marital-status)? Женатыми считаем тех, у кого marital-status начинается с Married (Married-civ-spouse, Married-spouse-absent или Married-AF-spouse), остальных считаем холостыми.

```
[13]: men = df[df["sex"] == "Male"]

      married = men["marital-status"].str.startswith("Married")

      men.groupby(married)["salary"].apply(lambda x: (x==">50K").mean())
```

```
[13]: marital-status
      False    0.490544
      True     0.494749
      Name: salary, dtype: float64
```

9. Какое максимальное число часов человек работает в неделю (признак hours-per-week)? Сколько людей работают такое количество часов и каков среди них процент зарабатывающих много?

```
[15]: workers = df[df["hours-per-week"] == max_hours]
      len(workers)
```

```
[15]: 132
```

10. Посчитайте среднее время работы (hours-per-week) зарабатывающих мало и много (salary) для каждой страны (native-country).

```
[16]: (workers["salary"] == ">50K").mean() * 100
```

```
[16]: np.float64(49.24242424242424)
```

11. Какое самое частое значение признака education? Выведите топ-5 значений с количеством.

```
[18]: df["education"].value_counts().head(5)
```

```
[18]: education
      Some-college    581
      HS-grad         564
      Masters         564
      11th            560
      Bachelors       558
      Name: count, dtype: int64
```

12. Для каждого уровня education посчитайте долю зарабатывающих >50K. Выведите топ-5 уровней образования по этой доле.

```
[19]: education_salary = df.groupby("education")["salary"].apply(
          lambda x: (x==">50K").mean()
      )

      education_salary.sort_values(ascending=False).head(5)
```

```
[19]: education
      11th            0.555357
      Some-college    0.512909
      Assoc-acdm      0.495396
      Prof-school     0.493554
      Masters         0.482270
      Name: salary, dtype: float64
```

13. Какая профессия (occupation) чаще всего встречается среди людей с доходом >50K? Выведите топ-5 профессий.

```
[20]: df[df["salary"]==">50K"]["occupation"].value_counts().head(5)
```

```
[20]: occupation
      Exec-managerial    391
      Tech-support       389
      Sales              371
      Adm-clerical       347
      Other-service      340
      Name: count, dtype: int64
```

14. Сравните среднее количество часов работы hours-per-week у групп salary (>50K и <=50K). Сделайте вывод: кто в среднем работает больше?

```
[21]: df.groupby("salary")["hours-per-week"].mean()
```

```
[21]: salary
      <=50K    39.234505
      >50K     39.534657
      Name: hours-per-week, dtype: float64
```

15. Найдите, как влияет наличие capital-gain:

- посчитайте долю людей с capital-gain > 0 среди >50K и среди <=50K;
- сравните эти доли.

```
[22]: df.groupby("salary")["capital-gain"].apply(lambda x: (x>0).mean())
```

```
[22]: salary
      <=50K    0.326885
      >50K     0.334820
      Name: capital-gain, dtype: float64
```

16. Для стран (native-country) найдите страну с наибольшей долей >50K, но учитывайте только страны, где не менее 50 наблюдений. Выведите страну, количество людей и долю >50K.

[23]:
```
country_stats = df.groupby("native-country").agg(
    total=("salary","count"),
    high_income=("salary", lambda x: (x==">50K").sum())
)

country_stats = country_stats[country_stats["total"] >= 50]

country_stats["share"] = country_stats["high_income"] / country_stats["total"]

country_stats.sort_values("share", ascending=False).head(1)
```

[23]:

native-country	total	high_income	share
India	730	385	0.527397

Вывод: были освоены базовые навыки работы в Jupyter Notebook для дальнейшего выполнения лабораторных по анализу данных: создание и оформление ноутбука, выполнение кода, получение вывода, простая визуализация и загрузка данных.